

PROYECTO FINAL DE MÓDULO

Microsoft Fabric & Power BI

AdventureWorks Sales Analysis

Autor: Ivan Delgado

Master en Business Intelligence & Data Analytics

Mayo 2026

1. Descripción del Dataset

AdventureWorks es una empresa ficticia de Microsoft dedicada a la fabricación y distribución de bicicletas y accesorios deportivos a escala mundial. El dataset utilizado en este proyecto recoge todas las transacciones de ventas registradas entre julio de 2017 y junio de 2020, abarcando tanto el canal de venta directa al cliente final (Internet) como el canal de distribución mayorista (Reseller).

Tabla	Registros	Descripción
FactSales	121.253 filas	Tabla de hechos: líneas de pedido de venta
DimProduct	397 productos	Catálogo de productos con categoría y precio
DimCustomer	18.484 clientes	Clientes de venta directa (canal Internet)
DimReseller	701 resellers	Distribuidores mayoristas por país
DimTerritory	11 territorios	Regiones de venta agrupadas por país y zona
DimDate	1.461 fechas	Calendario fiscal con año, trimestre y mes
DimSalesOrder	121.253 registros	Canal y número de pedido por línea


Las 4 categorías de producto presentes en el dataset son: Bikes (bicicletas), Components (componentes), Clothing (ropa deportiva) y Accessories (accesorios). Bikes representa la categoría con mayor volumen de ventas con diferencia, concentrando más del 80% de la facturación total.

2. Arquitectura de Datos en Microsoft Fabric

El proyecto implementa una arquitectura medallón (Bronze → Silver) sobre Microsoft Fabric, aprovechando el Lakehouse como almacén centralizado de datos y PySpark para las transformaciones.

2.1 Ingesta de datos — Capa Bronze

Se creó el Lakehouse LH_AdventureWorks en el workspace IvanDelgado de Microsoft Fabric. Los 7 archivos CSV originales se cargaron en la carpeta Files/bronze/ del Lakehouse, representando los datos en crudo sin ningún tipo de transformación.



2.2 Transformación — Capa Silver

Se desarrolló el notebook AdventureWorks_Silver_Transform utilizando PySpark. Las transformaciones aplicadas sobre los datos son las siguientes:

- Eliminación de registros inválidos: filtrado de filas donde CustomerKey = -1 y ResellerKey = -1 simultáneamente, que corresponden a registros sin asignación de cliente ni distribuidor.
- Conversión de claves de fecha: las columnas OrderDateKey, DueDateKey y ShipDateKey almacenadas en formato numérico yyyyMMdd se convirtieron a tipo Date real para facilitar el análisis temporal.
- Eliminación de duplicados: se aplicó deduplicación sobre SalesOrderLineKey para garantizar la unicidad de cada línea de pedido.
- Renombrado y normalización de columnas: se eliminaron espacios y caracteres especiales de todos los nombres de columna para asegurar compatibilidad con Delta Lake y Power BI.
- Tipado correcto de columnas numéricas: las columnas de precio y coste (StandardCost, ListPrice) se castearon a tipo Double; las columnas monetarias se definieron como Currency en Power BI.

Las 6 tablas resultantes se guardaron en formato Delta Lake en la sección Tables/ del Lakehouse, quedando disponibles para su consumo desde Power BI Desktop.

+ Código + Markdown



AdventureWorks — Transformación Bronze → Silver

Microsoft Fabric | Data Engineering

Dataset: AdventureWorks Sales (Microsoft) Objetivo: limpieza, tipado y normalización de tablas para modelo en estrella

```

1 from pyspark.sql import functions as F
2 from pyspark.sql.types import *
3
4 fact_sales = spark.read.option("header","true").option("inferSchema","true").csv("Files/bronze/FactSales.csv")
5 dim_data = spark.read.option("header","true").option("inferSchema","true").csv("Files/bronze/DimData.csv")
6 dim_product = spark.read.option("header","true").option("inferSchema","true").csv("Files/bronze/DimProduct.csv")
7 dim_customer = spark.read.option("header","true").option("inferSchema","true").csv("Files/bronze/DimCustomer.csv")
8 dim_territory = spark.read.option("header","true").option("inferSchema","true").csv("Files/bronze/DimTerritory.csv")
9 dim_reseller = spark.read.option("header","true").option("inferSchema","true").csv("Files/bronze/DimReseller.csv")
10 dim_salesorder = spark.read.option("header","true").option("inferSchema","true").csv("Files/bronze/DimSalesOrder.csv")
11
12 print("-> CSVs cargados correctamente desde Bronze")
13 fact_sales.printSchema()

```

[7] ✓ - Command executed in 5 s 986 ms by Enero - ivanwillmiller on 18/5/2026, 23:51:10

PySpark (Python)

1. Limpieza de FactSales

Transformaciones aplicadas:

- Eliminación de registros inválidos (CustomerKey = -1 y ResellerKey = -1)
- Conversión de claves de fecha (yyyyMMdd) a tipo Date real
- Eliminación de duplicados por SalesOrderLineKey
- Renombrado de columnas a nombres limpios sin espacios

```

1 fact_silver <- fact_sales \
2   .filter(!((f.col("CustomerKey") == -1) & (f.col("ResellerKey") == -1))) \
3   .dropDuplicates(["SalesOrderLineKey"]) \
4   .withColumn("OrderDate", F.to_date(F.col("OrderDateKey").cast("string"), "yyyyMMdd")) \
5   .withColumn("DueDate", F.to_date(F.col("DueDateKey").cast("string"), "yyyyMMdd")) \
6   .withColumn("ShipDate", F.to_date(F.col("ShipDateKey").cast("string"), "yyyyMMdd")) \
7   .withColumnRenamed("Order Quantity", "OrderQuantity") \
8   .withColumnRenamed("Unit Price", "UnitPrice") \
9   .withColumnRenamed("Extended Amount", "ExtendedAmount") \
10  .withColumnRenamed("Unit Price Discount Pct", "DiscountPct") \
11  .withColumnRenamed("Sales Amount", "SalesAmount") \
12  .withColumnRenamed("Total Product Cost", "TotalCost") \
13  .select("SalesOrderLineKey", "CustomerKey", "ResellerKey", "ProductKey",
14         "SalesTerritoryKey", "OrderDate", "DueDate", "ShipDate",
15         "OrderQuantity", "UnitPrice", "DiscountPct", "SalesAmount", "TotalCost")
16
17 print(f" -> FactSales Silver: {fact_silver.count()} filas")
18 fact_silver.show(5)

```

[*] ✓ - Command executed in 2 s 135 ms by Enero - ivanwilfrido on 18/5/2026, 23:51:20 PySpark (Python)

[illegible]

2. Limpieza de dimensiones

Transformaciones aplicadas por tabla:

- **DimProduct**: tipado de precios a Double, eliminación de duplicados
- **DimCustomer**: filtrado de registros [Not Applicable], renombrado de columnas
- **DimTerritory**: eliminación de duplicados
- **DimReseller**: filtrado de registros [Not Applicable], renombrado de columnas
- **DimDate**: conversión de columna Date a tipo DateType real

```
1 dim_product_silver = dim_product \
2   .filter(F.col("ProductKey").isNotNull()) \
3   .withColumn("StandardCost", F.col("Standard Cost").cast(DoubleType())) \
4   .withColumn("ListPrice", F.col("List Price").cast(DoubleType())) \
5   .drop("Standard Cost", "List Price") \
6   .dropDuplicates(["ProductKey"]) \
7
8 dim_customer_silver = dim_customer \
9   .filter(F.col("Customer") != "[Not Applicable]") \
10  .dropDuplicates(["CustomerKey"]) \
11  .withColumnRenamed("Customer ID", "CustomerID") \
12  .withColumnRenamed("State-Province", "StateProvince") \
13  .withColumnRenamed("Country-Region", "Country") \
14  .withColumnRenamed("Postal Code", "PostalCode") \
15
16 dim_territory_silver = dim_territory \
17  .dropDuplicates(["SalesTerritoryKey"]) \
18
19 dim_reseller_silver = dim_reseller \
20  .filter(F.col("Reseller") != "[Not Applicable]") \
21  .withColumnRenamed("Reseller ID", "ResellerID") \
22  .withColumnRenamed("Business Type", "BusinessType") \
23  .withColumnRenamed("State-Province", "StateProvince") \
24  .withColumnRenamed("Country-Region", "Country") \
25  .withColumnRenamed("Postal Code", "PostalCode") \
26  .dropDuplicates(["ResellerKey"]) \
27
28 dim_date_silver = dim_date \
29  .withColumn("date", F.col("Date").cast(DateType())) \
30  .dropDuplicates(["DateKey"]) \
31
32 print("-> Dimensiones limpias:")
33 print(f" DimProduct: {dim_product_silver.count()} filas")
34 print(f" DimCustomer: {dim_customer_silver.count()} filas")
35 print(f" DimDate: {dim_date_silver.count()} filas")
36 print(f" DimTerritory: {dim_territory_silver.count()} filas")
37 print(f" DimReseller: {dim_reseller_silver.count()} filas")
38
39 ✓ - Command executed in 2 s 355 ms by Enero - ivanwilfrido on 18/5/2026, 23:51:22
```

-> Dimensiones limpias:
DimProduct: 397 filas
DimCustomer: 18484 filas
DimDate: 1461 filas
DimTerritory: 11 filas
DimReseller: 781 filas

3. Escritura de tablas Silver en el Lakehouse

Las tablas se guardan en formato Delta Lake en la capa **Tables/** del Lakehouse. Esto las hace accesibles directamente desde Power BI Desktop mediante el conector de Fabr

```
1 from pyspark.sql import functions as F
2 import re
3
4 def clean_col_names(df):
5     """Limpia nombres de columnas: elimina caracteres especiales"""
6     for col in df.columns:
7         clean = re.sub(r'[,;{}()\n\t= ]', '_', col).strip('_')
8         if clean != col:
9             df = df.withColumnRenamed(col, clean)
10    return df
11
12 fact_silver_clean = clean_col_names(fact_silver)
13 dim_product_clean = clean_col_names(dim_product_silver)
14 dim_customer_clean = clean_col_names(dim_customer_silver)
15 dim_territory_clean = clean_col_names(dim_territory_silver)
16 dim_reseller_clean = clean_col_names(dim_reseller_silver)
17 dim_date_clean = clean_col_names(dim_date_silver)
18
19 fact_silver_clean.write.mode("overwrite").format("delta").saveAsTable("FactSales")
20 dim_product_clean.write.mode("overwrite").format("delta").saveAsTable("DimProduct")
21 dim_customer_clean.write.mode("overwrite").format("delta").saveAsTable("DimCustomer")
22 dim_territory_clean.write.mode("overwrite").format("delta").saveAsTable("DimTerritory")
23 dim_reseller_clean.write.mode("overwrite").format("delta").saveAsTable("DimReseller")
24 dim_date_clean.write.mode("overwrite").format("delta").saveAsTable("DimDate")
25
26 print("- Tablas Delta guardadas en el Lakehouse")
27 print(" Listas para conectar desde Power BI Desktop")
28
29 ✓ - Command executed in 30 s 953 ms by Enero - ivanwilfrido on 18/5/2026, 23:51:53
```

- Tablas Delta guardadas en el Lakehouse
Listas para conectar desde Power BI Desktop

```
1 # Ver qué tablas existen en el Lakehouse
2 tables = spark.sql("SHOW TABLES").collect()
3 print(f"Tablas encontradas: {len(tables)}")
4 for t in tables:
5     print(f" {t}")
6
7 ✓ - Command executed in 769 ms by Enero - ivanwilfrido on 18/5/2026, 23:52:45
```

Tablas encontradas: 6

Row(namespace='IvanDelgado.LH_AdventureWorks.dbo', tableName='dimcustomer', isTemporary=False)
Row(namespace='IvanDelgado.LH_AdventureWorks.dbo', tableName='dimdate', isTemporary=False)
Row(namespace='IvanDelgado.LH_AdventureWorks.dbo', tableName='dimproduct', isTemporary=False)
Row(namespace='IvanDelgado.LH_AdventureWorks.dbo', tableName='dimreseller', isTemporary=False)
Row(namespace='IvanDelgado.LH_AdventureWorks.dbo', tableName='dimterritory', isTemporary=False)
Row(namespace='IvanDelgado.LH_AdventureWorks.dbo', tableName='factsales', isTemporary=False)

Pipeline Bronze → Silver completado


Tabla	Capa	Formato
FactSales	Silver	Delta Lake
DimProduct	Silver	Delta Lake
DimCustomer	Silver	Delta Lake
DimTerritory	Silver	Delta Lake
DimReseller	Silver	Delta Lake
DimDate	Silver	Delta Lake

3. Modelo de Datos en Estrella

En Power BI Desktop se implementó un modelo de datos en esquema estrella con FactSales como tabla de hechos central y 6 tablas de dimensiones. Todas las relaciones son de cardinalidad Varios a uno (*:1) con dirección de filtro única, siguiendo las mejores prácticas de modelado dimensional.

Tabla origen (FactSales)	Columna clave	Tabla destino
FactSales	OrderDateKey → DateKey	DimDate
FactSales	ProductKey	DimProduct
FactSales	CustomerKey	DimCustomer
FactSales	ResellerKey	DimReseller
FactSales	SalesTerritoryKey	DimTerritory
FactSales	SalesOrderLineKey	DimSalesOrder


Los tipos de dato se validaron y corrigieron en Power Query (Editor avanzado M): columnas monetarias como Currency.Type, fechas como type date, porcentajes como Percentage.Type y claves de dimensión como Int64.Type.



4. Medidas DAX

Se crearon 9 medidas DAX en la tabla FactSales para dar soporte a los análisis del informe:

Medida	Fórmula DAX	Resultado
Total Ventas	SUM(FactSales[SalesAmount])	109,81 mill. €
Num Pedidos	DISTINCTCOUNT(FactSales[SalesOrderLineKey])	121.253
Ticket Medio	DIVIDE([Total Ventas], [Num Pedidos], 0)	905,62 €
Margen Bruto	SUM(SalesAmount) - SUM(TotalProductCost)	12,55 mill. €
% Margen	DIVIDE([Margen Bruto], [Total Ventas], 0)	11,43 %
Ventas YTD	TOTALYTD([Total Ventas], DimDate[Date])	Acumulado anual
Ventas Año Anterior	CALCULATE([Total Ventas], SAMEPERIODLASTYEAR(...))	Comparativa YoY
Ventas Internet	CALCULATE([Total Ventas], DimSalesOrder[Channel]="Internet")	29,36 mill. €
Ventas Reseller	CALCULATE([Total Ventas], DimSalesOrder[Channel]="Reseller")	80,45 mill. €




5. Informe Power BI — 4 Páginas

El informe está compuesto por 4 páginas interconectadas mediante botones de navegación, con un diseño visual coherente basado en una paleta de colores verde salvia y azul marino.


Página 1 — Resumen (Sales Overview)

- 4 tarjetas KPI: Total Ventas (109,81 mill. €), Num Pedidos (121.253), Margen Bruto (12,55 mill. €) y Ticket Medio (905,62 €).
- Gráfico de área: evolución mensual de Total Ventas de julio 2017 a junio 2020, con tendencia creciente hasta 2019 y caída en 2020.
- Gráfico de barras horizontales: Total Ventas por categoría de producto. Bikes lidera con más del 80% de la facturación.
- Segmentación por FiscalYear y Channel para filtrado interactivo.




Página 2 — Detalle por Categoría

- Tabla jerárquica con drill-down: Category > Subcategory > Product con Total Ventas, Num Pedidos y Ticket Medio.
- Gráfico de barras por Region con Total Ventas por territorio.
- Drillthrough activo: desde la página Resumen, clic derecho en cualquier categoría del gráfico de barras permite navegar directamente a esta página filtrada por esa categoría.




Página 3 — Canal de Ventas

- 2 tarjetas KPI: Ventas Internet (29,36 mill. € — 26,74%) y Ventas Reseller (80,45 mill. € — 73,26%).
- Gráfico de barras agrupadas: comparativa Reseller vs Internet por categoría de producto.
- Gráfico de donut: distribución porcentual del total de ventas por canal.
- Gráfico de líneas temporal: evolución mensual de ambos canales de 2017 a 2020.



Página 4 — Análisis Geográfico


- Gráfico de barras agrupadas: Total Ventas y Margen Bruto por Region, destacando Southwest como la región más rentable.
- Mapa de burbujas ArcGIS: distribución geográfica de ventas por país con tamaño proporcional al volumen.
- Tabla de resumen: Region, Total Ventas, Margen Bruto, % Margen y Num Pedidos por región.
- Treemap: distribución por grupo geográfico (North America 73,26%, Europe, Pacific).



6. Interactividad del Informe

El informe incorpora los siguientes elementos de interactividad:

- Navegación entre páginas: botones en el header de cada página permiten cambiar entre Resumen, Detalle, Canal y Geografía con un solo clic.
- Drillthrough: desde el gráfico de categorías en Resumen, el usuario puede hacer clic derecho sobre una categoría y seleccionar 'Obtener detalles' para navegar a la página Detalle con los datos filtrados automáticamente para esa categoría.
- Filtros cruzados: todos los visuals de cada página interactúan entre sí. Al seleccionar un elemento en cualquier gráfico, el resto se filtra automáticamente.
- Segmentaciones: la página Resumen incluye filtros de FiscalYear y Channel que afectan a todos los visuals de la página simultáneamente.



7. Conclusiones

El proyecto demuestra el flujo completo de un proyecto de Business Intelligence moderno: desde la ingesta de datos raw en un Lakehouse de Microsoft Fabric, pasando por la transformación y limpieza con PySpark, hasta la creación de un modelo analítico en estrella y un informe interactivo en Power BI.

Los datos de AdventureWorks revelan que el canal Reseller representa el 73% de las ventas totales, que las bicicletas son el producto estrella con más del 80% de la facturación, y que North America concentra la mayor parte del negocio. El margen bruto del 11,43% indica un negocio con márgenes ajustados donde la eficiencia en costes es clave.